

Guía de Actividades Práctico-Experimentales Nro. 006

1. Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	2
Resultado de aprendizaje de la unidad	Evalúa el comportamiento probabilístico de variables aleatorias continuas mediante el ajuste a la distribución Normal y el cálculo de áreas bajo la curva, aplicando estandarización (puntajes Z) para la toma de decisiones basada en datos empíricos.
Práctica Nro.	007
Título de la Práctica	Distribuciones Muestrales y Teorema del Límite Central (TLC) mediante Simulación Estocástica
Nombre del Docente	Cristian Ramiro Narváez Guillén
Fecha	Martes 26 de mayo del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

2. Objetivo(s) de la Práctica:

- **Demostrar** computacionalmente el Teorema del Límite Central (TLC) extrayendo múltiples muestras aleatorias de distribuciones poblacionales marcadamente asimétricas (no normales) mediante programación en Python.
- **Aplicar** técnicas de remuestreo (bootstrapping básico) sobre el conjunto de datos regional del Proyecto Integrador, observando el comportamiento de las medias de submuestras empíricas (ABP).
- **Investigar** el impacto del tamaño de la muestra (n) en la reducción del Error Estándar de la Media (SE), validando matemáticamente la ley de los grandes números (ABI).

3. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional en formato .csv o .xlsx (seleccionado y limpiado en las semanas 1 y 2).
- Conexión a Internet estable y continua.
- Navegador web actualizado (Chrome, Firefox o Edge).
- Repositorio del proyecto (GitHub/GitLab) para control de versiones (opcional, pero recomendado).

4. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

5. Procedimiento / Metodología

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante resolverá el desafío de aplicar modelos de inferencia sobre variables regionales que inicialmente no cumplen el supuesto de normalidad, apoyándose en el poder del TLC.
- **ABI (Aprendizaje Basado en Investigación):** Indagación empírica y visual sobre qué sucede matemáticamente con la varianza poblacional cuando es fraccionada por el tamaño de la muestra ($\sqrt{n}$).
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica de simulación individual, seguida de una plenaria grupal de los equipos del Proyecto Integrador.

Tarea 1: Generación de una Población Asimétrica (No Normal)

El Teorema del Límite Central establece que, dada una población con media μ y varianza finita σ^2 , la distribución de las medias muestrales $\bar{X}$ se aproximará a una distribución Normal $N(\mu, \frac{\sigma^2}{n})$ a medida que el tamaño de la muestra n aumenta.

1. Abra un nuevo Jupyter Notebook llamado APE_008_TLC.ipynb.

2. Simulemos el tiempo de permanencia de usuarios en un portal web (variable típicamente asimétrica positiva) utilizando una distribución Exponencial con $\lambda = 0.5$ (media poblacional $\mu = 2$).

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# 1. Creación de la Población "Universo" (Altamente asimétrica)
np.random.seed(42)
poblacion_exponencial = np.random.exponential(scale=2.0, size=100000)

mu_pob = np.mean(poblacion_exponencial)
sigma_pob = np.std(poblacion_exponencial)

print(f"--- Parámetros Poblacionales Reales ---")
print(f"Media ( $\mu$ ): {mu_pob:.4f}")
print(f"Desviación Estándar ( $\sigma$ ): {sigma_pob:.4f}")

# Visualización de la Población Original
plt.figure(figsize=(8, 4))
sns.histplot(poblacion_exponencial, bins=50, kde=True, color='orange')
plt.title("Distribución Poblacional (Exponencial) - Claramente NO Normal")
plt.xlabel("Tiempo de Permanencia")
plt.ylabel("Frecuencia")
plt.axvline(mu_pob, color='red', linestyle='dashed', label=f'Media: {mu_pob:.2f}')
plt.legend()
plt.show()
```

Tarea 2: Simulación Estocástica del Teorema del Límite Central

1. Para demostrar el TLC, vamos a extraer $k = 1000$ muestras aleatorias de tamaño $n = 30$ de nuestra población asimétrica. Calcularemos la media de cada muestra y graficaremos la distribución de estas 1000 medias.

```
# Parámetros de la simulación
tamaño_muestra = 30 # n
```



unl

Universidad
Nacional
de Loja

```
numero_muestras = 1000 # k
```

```
# Array para almacenar las medias de cada muestra
```

```
medias_muestrales = []
```

```
# Bucle de Monte Carlo simple
```

```
for _ in range(numero_muestras):
```

```
    # Extraer muestra aleatoria sin reemplazo
```

```
    muestra = np.random.choice(poblacion_exponencial,  
size=tamaño_muestra, replace=False)
```

```
    # Calcular y guardar la media
```

```
    medias_muestrales.append(np.mean(muestra))
```

```
# Estadísticos de la Distribución Muestral
```

```
media_de_medias = np.mean(medias_muestrales)
```

```
error_estandar_empirico = np.std(medias_muestrales)
```

```
error_estandar_teorico = sigma_pob / np.sqrt(tamaño_muestra)
```

```
print(f"--- Estadísticos de las Medias Muestrales (n={tamaño_muestra}) ---")
```

```
print(f"Media de las Medias Muestrales ( $E[\bar{X}]$ ): {media_de_medias:.4f}")
```

```
print(f"Error Estándar Empírico ( $\sigma_{\bar{X}}$ ): {error_estandar_empirico:.4f}")
```

```
print(f"Error Estándar Teórico ( $\sigma/\sqrt{n}$ ): {error_estandar_teorico:.4f}")
```

```
# Visualización de la convergencia a la Normal
```

```
plt.figure(figsize=(8, 4))
```

```
sns.histplot(medias_muestrales, bins=30, kde=True, color='blue')
```

```
plt.title(f"Distribución de las Medias Muestrales (n={tamaño_muestra}) -  
¡Convergencia a la Normal!")
```

```
plt.xlabel("Valor de las Medias Muestrales")
```

```
plt.ylabel("Frecuencia")
```

```
plt.axvline(media_de_medias, color='red', linestyle='dashed', label=f" $E[\bar{X}]$ :  
{media_de_medias:.2f}")
```

```
plt.legend()
```

```
plt.show()
```

Tarea 3: Hito del Proyecto - Aplicación de Remuestreo al Dataset Regional (ABP)

1. Importe su dataset regional mediante pandas.

2. Elija la variable continua analizada en la Semana 7 (que quizá probó no ser normal con el test de Shapiro-Wilk).
3. Adapte el bucle for de la Tarea 2 para extraer 500 muestras de tamaño $n = 40$ directamente de la columna de su DataFrame (utilice `df['variable'].sample(n=40, replace=True)`).
4. Grafique el histograma de las medias obtenidas de su dataset regional. Observe y redacte una justificación de cómo esto soluciona problemas de asimetría para futuras predicciones del proyecto.

Tarea 4: ABI - Análisis del Error Estándar y la Ley de los Grandes Números

El Error Estándar de la media se define como $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$.

1. Escriba un script que realice la simulación de la Tarea 2 pero iterando sobre una lista de diferentes tamaños de muestra: `tamanos_n = [5, 10, 30, 50, 100, 500]`.
2. Para cada n , guarde la desviación estándar de las medias resultantes (el error estándar empírico).
3. Genere un gráfico de líneas tipo *scatter plot* conectando los puntos donde el eje X sea el tamaño de la muestra (n) y el eje Y sea el Error Estándar ($\sigma_{\bar{x}}$).
4. Documente en formato Markdown la forma geométrica de la curva generada (decaimiento asintótico) y su implicación económica al momento de recolectar datos en ingeniería.

6. Resultados esperados:

- Comprensión de los conceptos básicos de probabilidad y teoría de conjuntos.
- Capacidad para generar espacios muestrales usando Python (itertools).
- Diferenciación entre los enfoques clásico, empírico y subjetivo de probabilidad.
- Verificación empírica de las probabilidades teóricas mediante simulación.
- Dataset regional seleccionado y documentado para el proyecto integrador.

7. Preguntas de Control:

- Basado en la Tarea 1 y 2, ¿por qué el Teorema del Límite Central es considerado el puente matemático fundamental entre la probabilidad descriptiva y la inferencia estadística?

- Demuestre con los resultados impresos en su consola de la Tarea 2, cómo se cumple la propiedad matemática fundamental de las distribuciones muestrales: $E[\bar{X}] = \mu$.
- En la Tarea 4, al graficar la curva del Error Estándar frente a n , ¿por qué la curva no desciende de forma lineal? Si usted como ingeniero requiere reducir el error estándar a la mitad, ¿cuántas veces debe incrementar el tamaño de la muestra?
- Históricamente, en estadística clásica se establece la regla de oro de $n \geq 30$ para asumir normalidad. Si la población regional que usted analizó en la Tarea 3 tiene una asimetría extrema (ej. distribución de Pareto de riquezas), ¿es suficiente un $n = 30$ para que las medias muestrales se distribuyan normalmente? Justifique.
- Diferencie conceptual y operativamente los términos **Desviación Estándar** (σ) de una muestra individual y el **Error Estándar de la Media** ($\sigma_{\bar{x}}$) calculado en sus simulaciones.

8. Rúbrica de Evaluación

Criterio Evaluado	Puntaje Máximo	Evidencia Esperada
1. Generación Poblacional (No Normal)	1.5 puntos	Ejecución de la Tarea 1, demostrando en gráfica la asimetría de la población base.
2. Simulación del TLC (Monte Carlo)	2.5 puntos	Bucle de simulación ejecutado correctamente (Tarea 2), con convergencia visible (gráfica de campana azul) y comparación teórica/empírica



		exacta.
3. Aplicación Regional (ABP)	2.5 puntos	Adaptación del código para operar sobre el DataFrame del Proyecto Integrador, mostrando remuestreo y normalidad resultante.
4. Análisis de Decaimiento del Error (ABI)	2.0 puntos	Bucle iterando sobre la lista tamanos_n y gráfico de decaimiento asintótico del error estándar correctamente generado.
5. Preguntas de Control	1.5 puntos	Respuestas teóricamente fundamentadas en Markdown, demostrando manejo técnico de conceptos (Error Estándar vs Desviación Estándar).
Total	10.0 puntos	

9. Bibliografía

Liste las fuentes utilizadas. Use normas **IEEE**. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.



[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	