

Guía de Actividades Práctico-Experimentales Nro. 009

1. Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	2
Resultado de aprendizaje de la unidad	Evalúa el comportamiento probabilístico de variables aleatorias continuas mediante el ajuste a la distribución Normal y el cálculo de áreas bajo la curva, aplicando estandarización (puntajes Z) para la toma de decisiones basada en datos empíricos.
Práctica Nro.	009
Título de la Práctica	Inferencia Estadística Multigrupo: Análisis de Varianza (ANOVA de 1 factor) y Pruebas Post-Hoc (Tukey)
Nombre del Docente	Cristian Ramiro Narváez Guillén
Fecha	Martes 22 de junio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

2. Objetivo(s) de la Práctica:

- **Diferenciar** y ejecutar computacionalmente la prueba T de Student para dos muestras independientes y la prueba T para muestras pareadas utilizando scipy.stats.
- **Aplicar** el diseño de un experimento comparativo (A/B Test) sobre dos segmentos categóricos del conjunto de datos regional del Proyecto Integrador, determinando si existe una diferencia estadísticamente significativa entre ellos (ABP).



unl

Universidad
Nacional
de Loja

- **Investigar** y validar matemáticamente el supuesto de igualdad de varianzas (homocedasticidad) mediante la ejecución del Test de Levene antes de comparar medias poblacionales (ABI).

3. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.x|

4. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

5. Procedimiento / Metodología

1. Enfoque PID:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante ya no compara su región contra un "valor ideal" teórico (Semana 10), sino que ahora divide sus datos regionales en dos grupos reales (ej. Zona Norte vs Zona Sur; Proveedor A vs Proveedor B) para descubrir disparidades sistémicas empíricas.
- **ABI (Aprendizaje Basado en Investigación):** Indagación sobre qué sucede cuando dos poblaciones tienen niveles de dispersión radicalmente distintos. Se investiga por qué la Prueba T de Welch ajusta automáticamente los grados de libertad para salvar la inferencia.
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual, con discusión de impactos en los grupos del Proyecto Integrador.



unl

Universidad
Nacional
de Loja

FEIRNNR - Carrera de Computación

Tarea 1: Prueba de Hipótesis para Dos Muestras Independientes (A/B Testing)

El objetivo es probar si las medias de dos poblaciones distintas son iguales ($H_0 : \mu_1 = \mu_2$, o de forma equivalente $H_0 : \mu_1 - \mu_2 = 0$).

Estadístico T (asumiendo varianzas iguales):

1.

$$T = \frac{\bar{X}_1 - \bar{X}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

Abra un nuevo Jupyter Notebook llamado APE_011_DosMuestras.ipynb.

2. Escenario: Usted es ingeniero de software y desea saber si el "Algoritmo A" consume menos memoria RAM que el "Algoritmo B". Ejecuta ambos en entornos aislados y registra el consumo en MB.

```
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import ttest_ind

# Datos empíricos (Consumo de RAM en MB)
np.random.seed(42)
memoria_algo_A = np.random.normal(loc=120.5, scale=12.0, size=35)
memoria_algo_B = np.random.normal(loc=128.2, scale=15.0, size=40)

alpha = 0.05

# Ejecución de la prueba T para muestras independientes (2 colas)
stat_ind, p_val_ind = ttest_ind(memoria_algo_A, memoria_algo_B,
equal_var=True)

print("--- A/B Testing: Algoritmo A vs Algoritmo B ---")
print(f"Media Algo A: {np.mean(memoria_algo_A):.2f} MB | Media Algo B: {np.mean(memoria_algo_B):.2f} MB")
```

```
print(f"Estadístico T: {stat_ind:.4f}")
print(f"Valor-p: {p_val_ind:.4e}")

if p_val_ind < alpha:
    print("Conclusión: Se RECHAZA H0. Existe una diferencia significativa en el
consumo de memoria.")
else:
    print("Conclusión: NO se rechaza H0. No hay evidencia de que los
algoritmos difieran en consumo.")

# Visualización
plt.figure(figsize=(8, 4))
sns.kdeplot(memoria_algo_A, fill=True, label="Algoritmo A")
sns.kdeplot(memoria_algo_B, fill=True, label="Algoritmo B")
plt.title("Comparación de Distribuciones de Consumo de RAM")
plt.xlabel("Consumo (MB)")
plt.legend()
plt.show()
```

Tarea 2: Prueba de Hipótesis para Muestras Pareadas (Dependientes)

Se usa cuando los datos de ambos grupos provienen de las *mismas* unidades de observación (ej. métricas del sistema "Antes" y "Después" de aplicar un parche de optimización). Aquí se evalúa la media de las diferencias ($d_i = X_{2i} - X_{1i}$).

1.

$$T = \frac{\bar{d} - \mu_d}{S_d / \sqrt{n}}$$

Escenario: Usted mide el tiempo de latencia de 15 servidores específicos *antes* y *después* de instalar un nuevo firewall.

2. Implemente y analice el código con `ttest_rel`:

```
from scipy.stats import ttest_rel
```

```
# Latencia en ms (las posiciones en los arrays corresponden al mismo
```

servidor)

```
latencia_antes = np.array([45, 52, 48, 55, 60, 42, 49, 58, 51, 46, 50, 47, 53, 59, 44])
```

```
latencia_despues = np.array([41, 50, 45, 50, 56, 40, 46, 53, 48, 42, 47, 45, 51, 55, 40])
```

```
# Prueba pareada (H1: la latencia "después" es menor, por tanto (antes - despues) > 0)
```

```
# Para evaluar si "después" bajó, usamos una prueba de cola superior sobre las diferencias (antes - despues)
```

```
# SciPy modernos permiten alternative='greater' en ttest_rel  
stat_rel, p_val_rel = ttest_rel(latencia_antes, latencia_despues,  
alternative='greater')
```

```
print("\n--- Análisis Pareado: Impacto del Nuevo Firewall ---")  
print(f"Media Diferencias (Antes - Después): {np.mean(latencia_antes - latencia_despues):.2f} ms")  
print(f"Estadístico T Pareado: {stat_rel:.4f}")  
print(f"Valor-p (1 cola): {p_val_rel:.4e}")
```

```
if p_val_rel < 0.05:
```

```
    print("Conclusión: Se RECHAZA H0. El firewall redujo significativamente la latencia.")
```

```
else:
```

```
    print("Conclusión: NO se rechaza H0. El firewall no mejoró la latencia.")
```

Tarea 3: Hito del Proyecto - Segmentación y Prueba A/B Regional (ABP)

1. Importe su dataset regional mediante pandas.
2. Identifique una variable **categorica** dicotómica (o filtre dos categorías específicas de una mayor, ej. ['Sector Rural', 'Sector Urbano'] o ['Enero', 'Julio']).
3. Extraiga la variable **cuantitativa** de interés para esos dos grupos separándolos en dos DataFrames o Arrays (grupo1 y grupo2).
4. Aplique un A/B Test usando ttest_ind.
5. Redacte un dictamen técnico-estadístico basado en el valor-^p obtenido, indicando si las políticas públicas o las decisiones de

ingeniería en la región deben tratar a ambos grupos por igual o de forma diferenciada.

Tarea 4: ABI - Supuesto de Homocedasticidad y Prueba de Levene

En la Tarea 1 y 3 usamos `equal_var=True`. Matemáticamente, la T de Student clásica exige que las varianzas poblacionales de ambos grupos sean iguales ($\sigma_1^2 = \sigma_2^2$).

1. Investigue el Test de Levene (`scipy.stats.levene`). Su Hipótesis Nula es que las varianzas *son* iguales.
2. Extraiga las variables `memoria_algo_A` y `memoria_algo_B` de la Tarea 1.
3. Ejecute el Test de Levene sobre ellas. Imprima el valor- p .
4. **Toma de decisión automatizada:** Escriba un pequeño bloque `if/else` en Python que verifique el p -valor de Levene: si $p < 0.05$, indique que existe *Heterocedasticidad* y proceda a ejecutar automáticamente la T de Student con el parámetro `equal_var=False` (Esta versión se conoce como la Prueba T de Welch).

6. Resultados esperados:

Al finalizar esta práctica, el estudiante será capaz de:

- **Implementar pruebas de hipótesis paramétricas:** Ejecutar correctamente pruebas Z y T en Python para la toma de decisiones estadísticas, seleccionando adecuadamente los parámetros según el conocimiento de la varianza poblacional.
- **Analizar datos empíricos del Proyecto Integrador:** Validar o refutar hipótesis sobre parámetros poblacionales de la región de estudio, aplicando el enfoque de Aprendizaje Basado en Problemas (ABP).
- **Evaluar la sensibilidad estadística:** Interpretar cómo el tamaño de la muestra afecta la significancia estadística (valor-p) mediante simulación computacional, distinguiendo entre relevancia estadística y relevancia práctica.
- **Comunicar hallazgos técnicos:** Redactar conclusiones basadas en evidencia estadística, explicando los riesgos asociados a los errores Tipo I y Tipo II en contextos de ingeniería real.
- **Documentar procesos de análisis:** Generar informes técnicos estructurados en Jupyter Notebook que integren código ejecutable,

visualizaciones gráficas y justificaciones teóricas en formato Markdown y LaTeX.

7. Preguntas de Control:

- ¿Por qué es un error metodológico grave aplicar una prueba T para muestras independientes (Tarea 1) en el escenario de la Tarea 2 (evaluación antes/después del firewall en los mismos servidores)? Explique el impacto en el término de covarianza.
- Describa matemáticamente y gráficamente qué es la "Prueba T de Welch". ¿Qué parámetro fundamental (calculado a partir de n y la varianza) ajusta esta prueba para evitar cometer Errores Tipo I al comparar distribuciones muy dispares?
- En el análisis de su Proyecto Integrador (Tarea 3), si el Intervalo de Confianza para la *diferencia de medias* ($\mu_1 - \mu_2$) incluyera al número cero (0), ¿cuál sería inevitablemente el resultado de su prueba de hipótesis usando $\alpha = 0.05$?
- Según lo investigado en la Tarea 4 (ABI), si el Test de Levene arroja un valor $p = 0.85$, ¿cuál es la conclusión estadística respecto a las varianzas y qué versión del Test T debería usar?
- En el mundo real del Data Science, ¿cómo difiere el concepto estadístico clásico enseñado hoy frente a la ejecución comercial de un "A/B Testing" en plataformas web (ej. comparar el color de un botón de compra)?

8. Conclusiones.

9. Rúbrica de Evaluación

Esta es la rúbrica simplificada, lista para ser cargada en Moodle:

Criterio Evaluado	Puntaje	Descripción / Evidencia Esperada
1. Pruebas Z y T (Implementación)	2.0	Ejecución técnica precisa usando scipy.stats (norm.sf, ttest_1samp), seleccionando los parámetros correctos según supuestos.
2. Análisis Regional (ABP)	2.5	Formulación correcta de hipótesis (H0/H1) y aplicación técnica rigurosa al dataset del Proyecto Integrador.
3. Análisis de Sensibilidad (ABI)	2.5	Simulación del efecto del tamaño de muestra (n) sobre el valor-p, incluyendo visualización en escala logarítmica.
4. Preguntas de Control	2.0	Respuestas técnicas fundamentadas en Markdown; distinción clara entre Error Tipo I y Tipo II en el contexto del proyecto.
5. Organización y Estilo	1.0	Notebook profesional, uso correcto de Markdown/LaTeX para ecuaciones y código debidamente documentado.
Total	10.0	

10. Bibliografía

Liste las fuentes utilizadas. Use normas **IEEE**. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



11. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	